

INTRODUZIONE CINECA

In questa guida verranno mostrati i passi essenziali da effettuare per poter creare una account Cineca ed utilizzare un cluster a cui delegare operazioni di computazione.

È ovviamente doveroso introdurre cosa sia il Cineca, in cosa può essere utile e la sua importanza, in modo da permettere una migliore comprensione di ciò che andremo a fare.

Il Cineca (<https://www.cineca.it/>) è un consorzio interuniversitario italiano, fondato nel 1967, con sede principale a Casalecchio di Reno (Bologna), fondamentale per attività di ricerca scientifica ed è considerato uno dei centri di calcolo più importanti al mondo.

I suoi utilizzi più importanti sono sicuramente il lavoro che svolge nel supporto alle ricerche universitarie, nella visualizzazione scientifica, nelle previsioni meteorologiche, nei progetti Antarex (ricerca farmacologica con un'elevata efficienza energetica) e tanto altro.

Il Cineca vanta strutture di primordine a livello globale, nonché supercomputer tra i più importanti e performanti al mondo, come Leonardo (4° nel ranking mondiale per potenza di calcolo) e Marconi - 100 (9° nel ranking mondiale).

CREAZIONE ACCOUNT CINECA

Adesso verranno mostrati, step-by-step, i passaggi da effettuare per poter iniziare a creare un account Cineca.

Il primo passo da effettuare è creare il profilo utente al link:

<https://userdb.hpc.cineca.it>

Una volta aperto il link verrà visualizzata la seguente schermata

The screenshot shows the 'User login' section on the left and the main portal content on the right. The 'User login' section includes fields for 'E-mail or username' and 'Password', a 'Log in' button, and links for 'Create new user' and 'Request new password'. Below these is an 'OpenID' button. The main content area is titled 'Welcome to HPC@CINECA User Portal' and contains a message: 'You need to be a registered member to access the UserDB portal.' It lists user capabilities: asking for an HPC username, checking active projects, accessing ISCRA and LISA sites for proposals, viewing HPC system statistics, and getting an OIDC token. A 'Please note' section states that existing users can login via OpenID or LDAP. The footer contains copyright information for SCAI and CINECA, and a link to the privacy policy.

CINECA UserDB
High Performance Computing

User login

E-mail or username *

Password *

• Create new user

• Request new password

Log in

OpenID

Welcome to HPC@CINECA User Portal

You need to be a registered member to access the UserDB portal.

Using this portal a user can:

- ask for an HPC username;
- check the active projects;
- access the ISCRA site for submitting HPC project proposals;
- access the LISA site for submitting HPC project proposals (reserved to researchers in Regione Lombardia);
- view statistics on the use of HPC systems (not available yet);
- Get an OIDC token bearer in order to authenticate to our services (e.g. UNICORE);
- and MUCH MORE.....

Please note:

If you already are a "HPC user" you can login using the OpenID button on the left, using your LDAP username and password

© Copyright 2023 SCAI - SuperComputing Applications and Innovation - CINECA PIVA: 00502591209 [Privacy](#) (for info: superc@cineca.it)

Sarà necessario cliccare “ Create new user “ per poter avviare il form di registrazione alla piattaforma, prestando attenzione alla lettura sulla privacy prima di accettarle.

The screenshot shows the 'My user' registration form. At the top, there are links for 'Home > My user', 'My user', 'Create new user', 'Log in', and 'Request new password'. The form has a section for 'E-mail' with a text input field and a note: 'A valid e-mail address. All e-mails from the system will be sent to this address. The e-mail address is not made public and will only be used if you wish to receive a new password or wish to receive certain news or notifications by e-mail.' Below this is the 'Personal Data' section, which is expanded. It contains fields for 'Name', 'Family name', 'Sex/Gender (as reported on your ID document)' (a dropdown menu), 'Date of Birth' (a date picker with Day, Month, and Year fields), 'Nationality' (a dropdown menu), and 'Nation of Birth' (a dropdown menu).

Home > My user

My user

Create new user Log in Request new password

E-mail *

A valid e-mail address. All e-mails from the system will be sent to this address. The e-mail address is not made public and will only be used if you wish to receive a new password or wish to receive certain news or notifications by e-mail.

Personal Data

Personal data

Name *

Family name *

Sex/Gender (as reported on your ID document) *

- Select a value -

Please indicate "-" in case anything else than M or F is reported on your document ID.

Date of Birth *

Day Month Year

Nationality *

- Select a value -

Nation of Birth *


- Select a value -

Qui, ovviamente, sarà necessario compilare il form in ogni sua sezione, con dati corretti e validi.

Una volta terminato questo breve passaggio, dalla piattaforma verrà inviata una mail da “userdb@cineca.it” all’indirizzo da noi indicato in fase di registrazione, nella quale sarà presente un link, utilizzabile una sola volta, il quale ci consentirà di impostare la password da associare all’account.

N.B. → Nel caso vengano riscontrati problemi o errori con il link a uso singolo, sarà possibile richiederne uno nuovo.

Completati questi brevi passaggi, sarà possibile effettuare l’accesso alla piattaforma.



The screenshot shows the CINECA UserDB User Portal login interface. The header features the CINECA logo (High Performance Computing) and the UserDB logo. Below the header is a blue navigation bar. The main content area is divided into two columns. The left column, titled 'User login', contains a form with fields for 'E-mail or username' (containing 'testmail@domain.xx') and 'Password' (masked with dots). Below the form are links for 'Create new user' and 'Request new password', and a 'Log in' button. The right column, titled 'Welcome to HPC@CINECA User Portal', contains a message: 'You need to be a registered member to access the UserDB portal.' and a list of user capabilities: 'ask for an HPC username;', 'check the active projects;', 'access the ISCRA site for submitting HPC project proposals;', 'access the LISA site for submitting HPC project proposals (reserved to researchers in Regione Lombardia);', and 'view statistics on the use of HPC systems (not available yet);'.

CINECA UserDB
High Performance Computing

User login

E-mail or username *
testmail@domain.xx

Password *
.....

- Create new user
- Request new password

Log in

Welcome to HPC@CINECA User Portal

You need to be a registered member to access the UserDB portal.

Using this portal a user can:

- ask for an HPC username;
- check the active projects;
- access the ISCRA site for submitting HPC project proposals;
- access the LISA site for submitting HPC project proposals (reserved to researchers in Regione Lombardia);
- view statistics on the use of HPC systems (not available yet);

Effettuato l’accesso, per poter ottenere le credenziali utili ad accedere ai Cluster, è necessario completare il proprio profilo utente.

User menu

- My user
- My projects
- My Legal Entities
- My DRES
- Log out

Available Services

- HPC Access
- ISCRA Access
- OIDC Token bearer

Home

View

Edit

PortalUser

Documents for HPC

Institution

Personal Data

Current password

Enter your current password to change the E-mail address or Password. [Request new password.](#)

E-mail address *

testmail@domain.xx

A valid e-mail address. All e-mails from the system will be sent to this address. The e-mail address is not made public and will only be used if you wish to receive a new password or wish to receive certain news or notifications by e-mail.

Password Requirements

Password

Password strength:

Confirm password

To change the current user password, enter the new password in both fields.

Picture

☐ Delete picture

Check this box to delete your current picture.

Upload picture

 Nessun file selezionato.

Your virtual face or picture. Pictures larger than 1024x1024 pixels will be scaled down.

- -'s
picture

Locale settings

Time zone

Select the desired local time and time zone. Dates and times throughout this site will be displayed using this time zone.

User menu

- My user
- My projects
- My Legal Entities
- My DRES
- Log out

Available Services

- HPC Access
- ISCRA Access
- OIDC Token bearer

Home >

> Edit

Documents for HPC profile

View

Edit

PortalUser

Documents for HPC

Institution

Personal Data

Document

Identity card number *

Identity card scan *

ID card type *

Delivered by *

Responsibilities Agreement *

☐ Not agree☒ Agree

User menu

- » My user
- » My projects
- » My Legal Entities
- » My DRES
- » Log out

Available Services

- » HPC Access
- » ISCRA Access
- » OIDC Token bearer

[Home](#) > [Edit](#)

Institution profile

[View](#) [Edit](#)

[PortalUser](#) [Documents for HPC](#) [Institution](#) [Personal Data](#)

Institution name *

Entity Name (Office,University,Department,...) *

Address *

Institution Postal code *

Institution Town *

Institution Country *

Institution Telephone

Institution Fax

Web page

Science Domain *

Other Science Domain

Save

Bisogna attendere la convalida delle informazioni inserire nei vari form, dopo la quale sarà possibile richiedere l'accesso all' High Performance Computing HPC.

Per fare ciò è necessario andare nella sezione “ HPC Access “ e cliccare il tasto “ Submit “.

User menu

- » My user
- » My projects
- » My Legal Entities
- » My DRES
- » Log out

Available Services

- » [HPC Access](#)
- » [ISCRAA](#) HPC Access
- » [OIDC Token bearer](#)

Welcome to HPC@CINECA User Portal

You need to be a registered member to access the UserDB portal.

Using this portal a user can:

- ask for an HPC username;
- check the active projects;
- access the ISCRA site for submitting HPC project proposals;
- access the LISA site for submitting HPC project proposals (reserved to researchers in Regione Lombardia);
- view statistics on the use of HPC systems (not available yet);
- Get an OIDC token bearer in order to authenticate to our services (e.g. UNICORE);
- and MUCH MORE.....

Please note:

If you already are a "HPC user" you can login using the OpenID button on the left, using your LDAP username and password

[Home](#)

HPC access

HPC (High Performance Computing) refers to the possibility to acquire a username for the Supercomputers in CINECA. Please note that, for technical reasons, the portal username and the HPC username are not the same.

Once you apply in order to gain HPC access you will be automatically added to the mailing list HPC news.

In order to unsubscribe to this mailing list send a mail to listserv@list.cineca.it

in the body --> "unsubscribe hpc-news"

in the subject --> any string...

as explained on the SCAI web portal related main page: [stay-tuned](#)

In order to apply for this service you have to:

- Complete the profile (Personal Data + Institution + HPC Docs) **[Personal Data OK] [Institution OK] [HPC Docs OK]**
- Ask for an authorisation **[OK]**

When both points are "OK" you can submit your request for authorisation.

[\[Submit\]](#)



È possibile richiedere l'accesso solo quando le voci [Personal Data], [Institution], [HPC Docs] e "Ask for an authorisation" sono seguite da un "OK" (così come in figura).

CREAZIONE ACCOUNT CLUSTER CINECA

Finiti questi passaggi bisogna attendere che venga spedita delle mail dal Cineca, nelle quali verranno comunicati i passaggi da seguire ed il nostro username, diverso da quello visibile in questa sezione, da utilizzare per accedere ai Cluster.

La prima mail avrà come oggetto “Access to CINECA HPC systems”, dove troveremo info fondamentali, come, appunto, l’username, linee guide ed url di accesso ai Cluster.

Dear

it is our pleasure to inform you that your request for accessing HPC systems or Cloud Computing in CINECA has been granted.
The username assigned to you is:

You will receive a separate email with a link to perform all the required action to setup your account on the CINECA-HPC Single Sign On (<https://sso.hpc.cineca.it>).

Read carefully the [CINECA HPC user guide](#) to find all the instructions on how to access CINECA resources, with particular attention to the [setup of the 2FA authentication](#).

The login hosts and url for each of the HPC and HPC Cloud services are:

GALILEO100 (DELL): <login.g100.cineca.it>
MARCONI (LENOVO): <login.marconi.cineca.it>
MARCONI100 (IBM): <login.m100.cineca.it>
OpenStack Cloud Computing dashboard: <https://adacloud.hpc.cineca.it>

Remember that you are allowed to connect **ONLY** to those systems in which you have an existent budget account.
For example if you try to connect to our Cloud resources without having a budget account on it, your login attempt will be denied.


Please note that all relevant information about HPC environment is posted on the HPC-NEWS mailing list.
Information about how to subscribe to the list can be found at the link: <https://www.hpc.cineca.it/content/stay-tuned>

If the request has not been issued by you, please discard this information and inform us by sending a message to superc@cinca.it

Regards,
HPC user manager


Nella seconda mail, con oggetto “CINECA HPC Single Sign On: mandatory actions required on your account”, sarà presente un link, con validità 24h, attraverso cui è possibile completare il nostro profilo.

In questo breve passaggio sarà necessario verificare la nostra mail, cambiare la password e definire un OTP, necessario alla procedura di 2FA.



In questo passaggio andiamo a verificare la mail utilizzata in atto di registrazione.

Successivamente verrà reso possibile impostare la password che utilizzeremo per accedere alle funzionalità dei Cluster Cineca.



Fatto questo bisognerà definire un OTP, ovvero utilizzare un software (ad esempio da telefono una valida alternativa è Google Authenticator), consentendo di rendere gli accessi il più sicuri possibili.



Mobile Authenticator Setup

You need to set up Mobile Authenticator to activate your account.

1. Install one of the following applications on your mobile:
FreeOTP
Google Authenticator
2. Open the application and scan the barcode:

[Unable to scan?](#)
3. Enter the one-time code provided by the application and click Submit to finish the setup.
Provide a Device Name to help you manage your OTP devices.

One-time code *

Device Name



Successivamente verrà mostrata una schermata nella quale è possibile visualizzare 12 codici di recupero (visualizzabili solo in questo passaggio), e sarà fondamentale salvarli e tenerli al sicuro, questo perché sono essenziali in caso di errori nell'uso dell'OTP.

N.B. → Non procedere fin quando non si è sicuri di aver salvato questi codici.



Recovery Authentication Codes

You need to set up Backup Codes to activate your account.

These recovery codes won't appear again after leaving this page
Make sure to print, download, or copy them to a password manager and keep them safe. Canceling this setup will remove these recovery codes from your account.

1: XPC3-9BIQ XXXX	7: 7Z9P-LAC XXXX
2: 9X6H-RWWY XXXX	8: 3WQF-BX XXXX
3: ZAXB-IUNE XXXX	9: WTVR-IQJ XXXX
4: 1VQE-WMNN XXXX	10: Y6D8-1JS XXXX
5: 3XIY-7QI XXXX	11: 5HH7-PBi XXXX
6: L56Z-JIS XXXX	12: PST2-YDC XXXX

[Print](#) [Download](#) [Copy](#)

☐ I have saved these codes somewhere safe

Complete setup



Una volta terminati questi passaggi ci sarà possibile connettersi ai Cluster per i quali abbiamo ottenuto l'autorizzazione.

Utilizzo Cluster

Questa guida si concentrerà sull'utilizzo del cluster Leonardo, utilizzando un Laptop casalingo con Ubuntu 22.xx come sistema operativo.

La guida potrebbe variare in base al S.O. utilizzato, è comunque possibile consultare guide ufficiali del Cineca ai seguenti Link:

MAC – LINUX → <https://wiki.u-gov.it/confluence/display/SCAIUS/Setup+client+step-cli%3A+Linux+and+Mac+users>

WINDOWS → <https://wiki.u-gov.it/confluence/display/SCAIUS/Setup+client+step-cli%3A+Windows+users>

Setup ambiente Ubuntu

Per rendere possibile l'utilizzo dei Cluster è necessario configurare il client step, ovvero un certificato di autorità CA necessario per utilizzare certificati SSH, che noi useremo per accedere da remoto ai Cluster. (<https://smallstep.com/docs/step-ca/#features>)

Utilizzando Ubuntu non ci è possibile eseguire da Terminale il comando

\$ sudo apt install step , questo perché installerebbe software diversi da quelli utili al nostro caso, generando errori.

Il primo passo da fare è eseguire il comando

\$ wget https://dl.smallstep.com/cli/docs-cli-install/latest/step-cli_amd64.deb

che ci permetterà di scaricare un software online che non genererà problemi.

Successivamente bisognerà eseguire il comando:

\$ sudo dpkg -i step-cli_amd64.deb , necessario per andare ad installare i pacchetti deb si step client.

Adesso bisognerà scaricare il certificato radice dall' autorità di certificazione ed impostare il corretto ambiente per poterlo utilizzare; per fare ciò è necessario eseguire

\$ step ca bootstrap --ca-url=https://sshproxy.hpc.cineca.it --fingerprint
2ae1543202304d3f434bdc1a2c92eff2cd2b02110206ef06317e70c1c1735ecd

che, nel caso tutto sia stato fatto correttamente, dovrebbe restituirci un output con il percorso del nostro certificato radice e il percorso dell'autorità di certificazione.

Una volta fatto tutto ciò bisogna utilizzare il certificato andando ad attivare l'agente SSH, attraverso il comando:

```
$ eval $(ssh-agent)
```

, e per ottenere il certificato bisogna eseguire il comando

```
$ step ssh login 'usermail@domain' --provisioner cineca-hpc
```

Questo comando, se eseguito correttamente, farà aprire, nel browser, una finestra del Cineca nel quale bisognerà effettuare l'accesso con Username/mail e password e successivamente bisognerà inserire l'OTP.



Una volta terminato l'accesso verrà generato il certificato necessario per accedere ai Cluster.

N.B. → Il certificato è temporaneo ed ha valenza di 12h, quindi bisognerà rigenerarlo con il comando “ \$ step ssh login ... “, anche dopo il riavvio del PC. Per visualizzare la il certificato è sufficiente eseguire uno dei due comandi seguenti

\$ ssh-add -L , oppure,

\$ step ssh list ,

mentre, per verificare la validità del certificato, basterà eseguire il comando

\$ step ssh list -raw '<user_mail>' | step ssh inspect

Una volta terminate questi passaggi, sarà possibile effettuare l'accesso al cluster attraverso un comando SSH, in questo caso si fa riferimento al cluster Leonardo

\$ ssh usernameCluster@login.leonardo.cineca.it

, e successivamente, nel caso non ci siano stati errori, basterà digitare ' yes ' .

Potrebbe riscontrarsi un errore con questo output:

```

@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@
@    WARNING: REMOTE HOST IDENTIFICATION HAS CHANGED!    @
@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@
IT IS POSSIBLE THAT SOMEONE IS DOING SOMETHING NASTY!
Someone could be eavesdropping on you right now (man-in-the-middle attack)!
It is also possible that a host key has just been changed.
The fingerprint for the ECDSA key sent by the remote host is
SHA256:Uz6iC5uYv2duVNZUiv6uGnh20MSjTIuT6zqkea/8XSE.
Please contact your system administrator.
Add correct host key in /root/.ssh/known_hosts to get rid of this message.
Offending ECDSA key in /root/.ssh/known_hosts:2

```

In questo caso si è presentato un problema per quanto riguarda le host keys, e per risolvere, bisognerà eliminare il certificato non valido.

Per modificare questo file, basterà seguire i seguenti passaggi:

\$ sudo nano -w /home/user/.ssh/known_hosts , che ci mostrerà il file interessato, e sarà necessario eliminare le righe presenti nel file.

Per poterle eliminare basterà usare la combinazione ' CTRL + K ' , che eliminerà la riga, poi si procede al salvataggio delle modifiche con ' CTRL + X ' , poi confermare con S e poi premere ' Invio ' .

Una volta effettuato l'accesso con il comando SSH, sul terminal avremo questa schermata

```

Welcome to:

LEONARDO

*****
* Atos Bull Sequana XH21355 "Da Vinci" Blade *
* Red Hat Enterprise Linux 8.6 (Ootpa) *
* *
* 3456 compute nodes with: *
*   - 32 cores Ice Lake at 2.60 GHz *
*   - 4 x NVIDIA Ampere A100 GPUs, 64GB *
*   - 512 GB RAM *
* *
* Internal Network: Nvidia Mellanox HDR DragonFly++ *
* SLURM 22.05 *
* *
* For a guide on Leonardo: *
* https://wiki.u-gov.it/confluence/display/SCAIUS/UG3.2%3A+LEONARDO+UserGuide *
* For support: superc@cineca.it *
*****

IN EVIDENCE:
- A new personal area $PUBLIC is available to share installations and/or
  data. Please, keep in mind that the $PUBLIC directory is by default open to
  everybody on the cluster, and your files are visible to all users.
- The automatic cleaning of the $SCRATCH area is NOT active at the moment
- RCM will be available soon
- The Data Centric partition of the cluster is currently not available
- Spack 0.19 is available with "module load spack"

Register this system with Red Hat Insights: insights-client --register
Create an account or view all your systems at https://red.ht/insights-dashboard

```

Creazione ambiente virtuale

Appena effettuato l'accesso al Cluster, abbiamo un ambiente di sviluppo asettico; è quindi necessario caricare sul cluster i moduli di sviluppo con le relative librerie. Per fare questo è sufficiente seguire questi prompt:

```
[ @login0 ~]$ module load profile/deeplrn
[ @login0 ~]$ module av cineca-ai
----- /leonardo/prod/opt/modulefiles/deeplrn/libraries -----
cineca-ai/3.0.0  cineca-ai/3.0.1
Key:
modulepath  default-version
```

Per caricare il modulo è sufficiente utilizzare il prompt

```
[ @login0 ~]$ module load cineca-ai/3.0.1
Loading cineca-ai/3.0.1
Loading requirement: cuda/11.8 zlib/1.2.13--gcc--11.3.0 openmpi/4.1.4--gcc--11.3.0-cuda-11.8
```

Un passo fondamentale che può esserci davvero utile, è la definizione di una ambiente virtuale, che ci permetterà di istanziare un ambiente a sé stante all'interno del cluster, dove possiamo installare librerie ed effettuare azioni, senza andare a modificare il sistema a noi dedicato.

Per creare questo ambiente basta seguire questi semplici passaggi:

```
[ @login0 ~]$ python -m venv _env --system-site-packages
[ @login0 ~]$ source _env/bin/activate
(_env) [ @login0 ~]$ deactivate
```

Nel dettaglio, con `$ python -m venv nome_ambiente --system-site-packages` , andiamo a creare il nostro ambiente virtuale, il quale sarà salvato all'interno della nostra partizione nel cluster.

Una volta creato, per poterci accedere è sufficiente attivarlo con il comando `$ source nome_ambiente/bin/activate` , che ci permetterà di essere all'interno dell'ambiente virtuale.

Da qui sarà possibile poi installare librerie senza modificare l'intero ambiente, e sarà possibile effettuare i nostri test senza il rischio di danneggiare nulla.

Una volta che abbiamo terminato con le esecuzioni all'interno del nostro ambiente virtuale, per tornare all'ambiente principale, sarà sufficiente scrivere il comando `$ deactivate`

TRASFERIMENTO FILE LAPTOP → CLUSTER

Una funzionalità fondamentale è sicuramente l'utilizzo di comandi SCP che forniscono la possibilità di trasferire dei file del nostro laptop al cluster, permettendoci di eseguire, ad esempio, software o codici che non potremmo eseguire al meglio su hardware casalinghi.

In questo caso specifico della guida, infatti, è stato necessario affidarsi ad un supercomputer per poter eseguire ed utilizzare al meglio possibile alcuni LLM (Large Language Model), i quali sono modelli basati su decine di miliardi di parametri, che, per ovvie ragioni, su PC casalinghi non possono essere utilizzati.

Quello che verrà mostrato in questi passaggi è il trasferimento di questi modelli da un laptop al cluster, in modo da poterli in seguito eseguire con Leonardo, permettendoci di non avere limitazioni e ottenendo risultati ottimali.

Il primo passo è sicuramente il trasferimento di file, in questo caso dei file .py, nei quali sono definiti ed utilizzati dei LLM (LLama, Mistral, ...), che verranno utilizzati per test generativi.

Per fare ciò, come detto precedentemente, si ricorre a comandi SCP, ovvero un comando che ci permette di trasferire dati in modo sicuro tra due posti geograficamente distanti.

Il comando, per il trasferimento di un file, è così definito:

`$ scp file.txt remote_username@IP:/remote/directory` , dove `remote_username` fa riferimento all'username, nel nostro caso, del cluster di destinazione, mentre in `IP` può essere inserito l'indirizzo IP oppure il nome dell'Host.

Immaginando di voler trasferire un file `Prova.txt` dal nostro PC alla directory 'Prove' nel cluster, possiamo utilizzare un output del tipo:

```
$ scp Prova.txt username@domain' :/leonardo/home/userexternal/username/Prove
```

dove in `username@domain` utilizzeremo la stessa stringa identificativa usata nel comando `ssh`.

Per visionare il percorso completo del path si può usare il comando `$pwd` , il quale percorso verrà poi utilizzato per trasferire i dati.

Una volta fatto ciò, per verificare concretamente il trasferimento, basterà connettersi al cluster con il comando `ssh` visto nelle sezioni precedenti, navigare dentro la directory 'Prove' con il comando

```
$ cd Prove/
```

 , e successivamente visualizzare il contenuto della cartella con il comando

```
$ ll
```

 , che ci farà visualizzare il contenuto della stessa, e, se tutto è andato bene sarà visualizzabile il file 'Prova.txt' .

Ovviamente ci è possibile aprire il file per visualizzarne il contenuto utilizzando il prompt

```
$ cat Prova.txt
```

Capito come funziona il trasferimento di file tra PC e Cluster Cineca, si mostrerà come trasferire, eseguire e valutare i LLM.

Perché utilizzare un cluster Cineca?

Durante lo studio ed utilizzo dei modelli LLM, sono state riscontrate numerose difficoltà nell'utilizzo degli stessi, questo dovuto alla loro grande richiesta di risorse computazionali.

Come definito precedentemente, questi modelli sono composti da miliardi di parametri, fino a centinaia di miliardi, e per essere eseguiti ed utilizzati sono necessarie delle risorse hardware fuori dal comune, non raggiungibili da dei pc normali.

È stato quindi necessario ricorrere ad una infrastruttura all'avanguardia, tra le migliori al mondo, per quanto riguarda l'utilizzo di infrastrutture e risorse hardware, ovvero il Cineca.

L'utilizzo di queste infrastrutture è però meno banale rispetto ad un pc comune, esso infatti è gestibile solo tramite linea di comandi, senza una vera e propria UI, e non permette, a meno di avere dei permessi speciali, di utilizzare ed accedere a siti internet esterni.

Un punto di grande difficoltà nasce dal fatto che, non essendo possibile l'utilizzo di internet e, quindi, di ricorrere a librerie e moduli che hanno bisogno di un collegamento a nodi esterni, come Huggingface, è fondamentale utilizzare soluzioni totalmente in locale.

Quindi quello che è necessario fare, per poter utilizzare questi modelli su un cluster Cineca, è scaricare totalmente in locale sul nostro Pc i modelli che desideriamo utilizzare per poi, tramite comandi Scp, trasferirli sul Cineca.

Per quanto riguarda il nostro obiettivo è quello di poter utilizzare Llama e Mistral con Leonardo, in modo da poter sfruttare le potenzialità hardware del Cineca.

Quindi, come precedentemente detto, è stato necessario scaricare i modelli sul nostro PC e poi, successivamente, trasferirli tramite appositi comandi al cluster.

Procedimenti per utilizzare Llama – Processo 1

Di seguito verrà mostrato uno dei due modi utilizzati per effettuare il download dei modelli in locale.

Download ed upload modelli

Un punto di grande difficoltà nasce dal fatto che, non essendo possibile l'utilizzo di internet e, quindi, di ricorrere a librerie e moduli che hanno bisogno di un collegamento a nodi esterni, è fondamentale utilizzare soluzioni totalmente in locale.

Quindi quello che è necessario fare per poter utilizzare questi modelli, è quello di trovare e scaricare totalmente in locale sul nostro Pc i modelli che si desiderano utilizzare, per poi, tramite comandi SCP, trasferirli sul Cineca.

LLaMA

Per quanto riguarda il download del modello LLaMA è innanzitutto necessario ottenere l'autorizzazione da Meta ed Huggingface creando degli account su quest'ultima piattaforma per poter inoltrare le suddette richieste.


Quindi ciò che è necessario fare per LLaMA è inserire le proprie credenziali sul sito <https://llama.meta.com/llama-downloads>, inoltrare la richiesta ed attendere la validazione in un lasso di tempo che va dalle 2h alle 48h.


Una volta accettata la richiesta si otterrà un URL, con validità di 24h, che ci consente di effettuare 5 download (nel caso il link scada è comunque possibile ottenerne uno nuovo in un tempo ristretto utilizzandole stesse credenziali).

N.B. : Dato che principalmente è necessario utilizzare comandi tramite terminale, si ricordi che per effettuare un copia o un incolla su terminale, non è possibile utilizzare le tipiche scorciatoie. Per copiare qualcosa presente nel terminale è necessario selezionare il testo ed utilizzare la scorciatoia 'Ctrl + Shift + c', mentre per incollare qualcosa nel terminale bisogna utilizzare il comando 'Ctrl + Shift + v', tenendo presente che non è necessario incollare anche il simbolo di inizio riga \$, il quale sarà presente di default per ogni comando nel terminale.

Download

Per avviare il download dei modelli bisogna accedere al sito <https://huggingface.co/> , effettuare il login e creare un token generabile dal sito andando nella sezione personale del profilo, cliccare 'Settings', 'Access Token' e generarne uno.





Access Tokens

User Access Tokens

[+ Create new token](#)

Access tokens authenticate your identity to the Hugging Face Hub and allow applications to perform actions based on token permissions. **Do not share your Access Tokens with anyone;** we regularly check for leaked Access Tokens and remove them immediately.

Fatto ciò è possibile ricercare il modello di interesse nella barra di ricerca ed avviare il download dopo aver completato il form ed accettato i termini e condizioni.

Avviato il download, verrà scaricato in locale una directory con il nome del modello, ed una volta terminato avremo il modello sul nostro PC.

Nel caso volessimo tentare di utilizzare il modello sul proprio PC, è necessario installare le dipendenze attraverso il comando da terminale:

```
$ pip install -e
```

dopo sarà possibile eseguire e modificare uno dei codici python presenti nella directory che possono essere utilizzati per testare il modello.

Per eseguire questi tipi di codici python è necessario utilizzare un comando torchrn o python come il seguente:

```
$ python3 percorso/cartella/modelloLLM/Example.py
```

è ovviamente necessario modificare, in base ai path personali nel pc,

'percorso/cartella/modelloLLM/Example.py' con l'effettivo percorso che contiene poi la directory.

Come detto precedentemente, anche con modelli piccoli è possibile che le componenti hardware di PC casalinghi non siano sufficienti ad eseguirli, riscontrando errori computazionali o di utilizzo eccessivo di memoria, i quali portano al crash dell'esecuzione, non permettendoci di fatto di ottenere risultati.

È per questo che per questi tipi di modelli sia necessario utilizzare dei supercomputer, come appunto Leonardo, il quale grazie alla sua potenza computazionale elevata permette il loro utilizzo.

Procedimenti per utilizzare Llama – Secondo metodo

Per quanto riguarda il download del modello Llama, un'alternativa è quella di seguire la guida del seguente sito: <https://github.com/facebookresearch/codellama> , e tramite questa guida ci è concesso scaricare il modello potendo scegliere tra diverse versioni.

Per poter avviare il download è innanzitutto necessario ottenere l'autorizzazione da Meta ed Huggingface, e per fare ciò è necessario creare degli account per poter effettuare le suddette richieste.

Quindi ciò che è necessario fare è inserire le proprie credenziali sul sito <https://llama.meta.com/llama-downloads> , inoltrare la richiesta ed attendere la validazione in un lasso di tempo che va dalle 2h alle 48h.

Quando la richiesta verrà accettata, otterremo una mail da Meta nel quale verremo informati della concessione per il download, nello specifico riceveremo un URL, con validità di 24h, il quale può essere utilizzato per 5 download (nel caso il link scada sarà comunque possibile ottenerne uno nuovo in un tempo ristretto utilizzandole stesse credenziali).

Una volta ottenuto questo, ciò che dovremo fare è eseguire il download sul nostro PC, e per fare ciò sarà necessario eseguire lo script ' download.sh ' , ovvero uno script presente all'interno della directory che scaricheremo.

N.B. -> Dato che principalmente è necessario utilizzare comandi tramite terminale, ricordiamo che per effettuare un copia o un incolla su terminale, non è possibile utilizzare le tipiche scorciatoie che utilizziamo di solito.

Per copiare qualcosa presente nel terminale è necessario selezionare il testo tramite mouse ed utilizzare la scorciatoia ' Ctrl + Shift + c ' mentre per incollare qualcosa nel terminale bisogna utilizzare il comando ' Ctrl + Shift + v ' , tenendo presente che non è necessario incollare anche il simbolo di inizio riga \$, il quale sarà presente di default per ogni comando nel terminale.

Passaggi passo-passo per Llama

Innanzitutto bisogna essere sulla pagina GitHub e scaricare quindi la directory a noi interessata, e per fare ciò è sufficiente cliccare sul bottone in alto a destra ' <> Code ' e cliccare poi il bottone per il download.

meta-llama / codellama Public

<> Code Issues 85 Pull requests 7 Actions Projects Security Insights

main 4 Branches 0 Tags Go to file Code

jgehring Updates for 70b release 1af62e1 · 3 months ago 22 Commits

.circleci	Initial commit	8 months ago
llama	Updates for 70b release	3 months ago
.gitignore	Updates for 70b release	3 months ago
CODE_OF_CONDUCT.md	Initial commit	8 months ago
CONTRIBUTING.md	Initial commit	8 months ago
LICENSE	Initial commit	8 months ago
MODEL_CARD.md	Updates for 70b release	3 months ago
README.md	Updates for 70b release	3 months ago
USE_POLICY.md	Initial commit	8 months ago
dev-requirements.txt	Initial commit	8 months ago
download.sh	Updates for 70b release	3 months ago

meta-llama / codellama Public

<> Code Issues 85 Pull requests 7 Actions Projects Security Insights

main 4 Branches 0 Tags Go to file Code

jgehring Updates for 70b release

.circleci	Initial commit	8 months ago
llama	Updates for 70b release	3 months ago
.gitignore	Updates for 70b release	3 months ago
CODE_OF_CONDUCT.md	Initial commit	8 months ago
CONTRIBUTING.md	Initial commit	8 months ago
LICENSE	Initial commit	8 months ago
MODEL_CARD.md	Updates for 70b release	3 months ago
README.md	Updates for 70b release	3 months ago
USE_POLICY.md	Initial commit	8 months ago
dev-requirements.txt	Initial commit	8 months ago

Clone

HTTPS GitHub CLI

<https://github.com/meta-llama/codellama.git>

Clone using the web URL

Open with GitHub Desktop

Download ZIP

Una volta fatto ciò verrà avviato il download del file ZIP il quale dovrà essere estratto nella destinazione da noi scelta, ad esempio nel nostro caso la directory 'home', ed una volta fatto ciò è necessario aprire il terminale con il percorso della directory da noi utilizzata ed utilizzare il comando: `$ bash download.sh`.

Fatto ciò nel terminale sarà visualizzato il seguente messaggio:

Enter the URL from email: , ed è qui che dovremo incollare l'URL ricevuto tramite mail

da Meta, ottenendo quindi qualcosa del genere:

Enter the URL from email:

https://download.llamameta.net/*?Policy=eyJTdGF0ZW1lbnQiOlt7InVuaXF1ZV9oYXNoIjoiOHlvaDE.....-Request-ID=xxxxxxx

Dopo. Premendo il tasto ‘ Invio’ della tastiera sarà possibile scegliere quale modello scaricare tra quelli disponibili, ad esempio è possibile scegliere tra Llama7b, Llama13B, Llama70B ed altri.

Nel nostro caso abbiamo scelto di testare Llama7B-Instruct, dato che gli altri modelli occupano molto spazio di archiviazione.

Scelto quindi il modello verrà avviato il download il quale verrà scaricato all’interno della directory che presenta lo script ‘ download.sh ‘.


Una volta terminato il download è necessario, tramite terminale con percorso la directory ‘codellama-main’, utilizzare il seguente comando:

\$ pip install -e , il quale ci permetterà di installare le dipendenze necessarie per utilizzare il modello.

In questa directory sono presenti alcuni codici d’esempio che potremo utilizzare per testare il modello scaricato (hardware permettendo).

È fondamentale tener conto del fatto che per utilizzarli è necessario fornire i percorsi della directory contenente il modello scaricato ed il percorso della carella contenente il file ‘ tokenizer.model ‘.

Nel nostro caso abbiamo:



	Nome	Dimension
	codellama.egg-info	5 oggetti
	CodeLlama-7b	4 oggetti
	llama	5 oggetti
	CODE_OF_CONDUCT.md	3,5 kB
	CONTRIBUTING.md	1,4 kB
	dev-requirements.txt	52 byte
	download.sh	2,2 kB
	example_completion.py	1,3 kB
	example_infilling.py	2,1 kB
	example_instructions.py	2,0 kB

Home / codellama-main / CodeLlama-7b			⋮	🔍	📁	▼	☰
Nome		▼		Dimensione			
📄	checklist.chk			150 byte			
📦	consolidated.00.pth			13,5 GB			
📄	params.json			163 byte			
📄	tokenizer.model			500,1 kB			

Per quanto riguarda la definizione dei path che deve utilizzare il modello possiamo utilizzare due strade, o definire direttamente tramite comando terminal i percorsi che il modello deve usare, o modificare il codice python andando a dichiararli.

Nel caso volessimo usare la prima strada è necessario utilizzare il comando:

```
$ torchrun --nproc_per_node 1 Example_competition.py \--ckpt_dir
/directory/path/CodeLlama-7b/ \--tokenizer_path /directory/path/CodeLlama-
7b/tokenizer.model \ --max_seq_len 192 --max_batch_size 4
```

Nel vostro caso sarà necessario modificare ‘ **/directory/path/CodeLlama-7b/** ‘ con l’effettivo percorso che contiene poi la directory CodeLlama-7b, e modificare **/directory/path/CodeLlama-7b/tokenizer.model**, inserendo lo stesso path utilizzato per il comando precedente.

È ovviamente possibile modificare anche i parametri di `nproc_per_node` , `max_seq_len`, `max_batch_size` ed inserirne altri.

Nel caso in cui si volesse utilizzare invece il secondo approccio è necessario modificare direttamente il codice python, andando a modificare la dichiarazione dei percorsi nei file.

Di seguito viene mostrato un file di prova, denominato prova2.py, nel quale vengono modificate le due righe che definiscono ‘ `ckpt_dir: str` ‘ e ‘ `tokenizer_path: str` ‘ nel seguente modo:

```

1 # Copyright (c) Meta Platforms, Inc. and affiliates.
2 # This software may be used and distributed according to the terms of the Llama 2 Community
  License Agreement.
3
4 from typing import Optional
5
6
7
8 from llama import Llama
9
10
11 def main(
12     #ckpt_dir = "/home/          /codellama-main/CodeLlama-7b/",
13     #tokenizer_path = "/home/          /codellama-main/CodeLlama-7b/tokenizer.model",
14
15
16     #temperature: float = 1.0,
17     #top_p: float = 2.0,
18     max_seq_len: int = 256,
19     max_batch_size: int = 4,
20     #max_gen_len: Optional[int] = None,
21 ):
22     generator = Llama.build(
23         ckpt_dir=ckpt_dir,
24         tokenizer_path=tokenizer_path,
25         max_seq_len=max_seq_len,
26         max_batch_size=max_batch_size,
27     )
28
29     prompts = [
30         "Say hi and talk about Italy!"
31     ]
32
33     results = generator.text_completion(
34         prompts,
35         #max_gen_len=max_gen_len,
36         #temperature=temperature,
37         #top_p=top_p,
38     )
39     for prompt, result in zip(prompts, results):
40         print(prompt)
41         print(f"> {result['generation']}")
42         print("\n=====\\n")
43
44
45 if __name__ == "__main__":
46     main()
47
48

```



Come detto precedentemente, anche con modelli piccoli, è possibile che le componenti hardware di PC casalinghi non siano adatti ad eseguirli, infatti spesso si riscontrano problemi computazionali o di utilizzo eccessivo di memoria, i quali portano al crash dell'esecuzione non permettendoci di ottenere risultati.

È per questo che per questi tipi di modelli è necessario utilizzare dei supercomputer, come appunto Leonardo, il quale grazie alla potenza computazionale permette il loro utilizzo.

Trasferimento modello Llama su Leonardo

Per poter trasferire Llama è necessario ricorrere ai comandi scp mostrati nelle sezioni precedenti.

Quello che dovremo fare è avviare il terminal nella directory che contiene la cartella 'codellama-main' ed effettuare un trasferimento 'ricorsivo', il quale permette di trasferire quindi l'intera directory.

Il comando da utilizzare è quindi :

```
$ scp -r codellama-main remote_username@IP: percorso/cartella/leonardo
```

Una volta terminato il processo di trasferimento che richiederà del tempo, dato che sarà necessario trasferire alcuni giga, il modello sarà finalmente presente sul nostro supercomputer.

Una volta fatto ciò, per poter utilizzare il modello è necessario creare un file .sh che ci permetterà di avviare l'esecuzione.

Nei supercomputer, infatti, spesso per poter avviare delle esecuzioni è necessario utilizzare dei comandi particolari, uno dei metodi più utilizzati sono sicuramente dei comandi SLURM.

Questi comandi ci permettono di definire quanta potenza di calcolo vogliamo instanziare per le varie esecuzioni, permettendoci anche di avviare delle esecuzioni in parallelo, consentendoci di velocizzare le operazioni.

Attraverso SLURM è possibile definire quanta RAM utilizzare, quanta GPU e molto altro, permettendoci di poter sfruttare al massimo le potenzialità di queste tipologie di computer.

Per fare ciò possiamo creare un file, tramite ad esempio il blocco note, un file contenente i comandi SLURM che poi trasferiremo al cluster per poi eseguirlo.

Nel caso specifico, lo script creato è il seguente:

```
#!/bin/bash

#SBATCH --account=lscrC_SustLLMs_0

#SBATCH --partition=boost_usr_prod

#SBATCH --qos=normal

#SBATCH --time=00:05:00

#SBATCH --error=%j-test.err          ## File di errore

#SBATCH --output=%j-test.out        ## File output

#SBATCH --cpus-per-task=8           ## number of CPUs per process

#SBATCH --nodes=1                   ## Number of nodes
```

```
#SBATCH --ntasks-per-node=2      ## MPI processes per node, massimo 8  
#SBATCH --mem-per-cpu=3000M  
#SBATCH --gres=gpu:4
```

```
torchrun percorso/cartella/leonardo/codellama-main/prova2.py \ --max_seq_len 500 --  
max_batch_size 4
```

Ovviamente un file di questo genere deve essere adatto ed adattato al supercomputer utilizzato, in base anche alla disponibilità della partizione utilizzata per le esecuzioni. Una volta creato questo file è necessario salvarlo con estensione .sh, ad esempio 'testlama.sh', ed inviarlo successivamente al supercomputer.

Fatto ciò, per poterlo utilizzare è sufficiente muoversi all'interno della destinazione nella quale abbiamo trasferito il file .sh ed utilizzare il comando:

```
$ sbatch testlama.sh .
```

Fatto ciò verrà avviato il processo, ovvero un job, che ci permetterà di eseguire il modello ed ottenere l'output, il quale nel caso specifico verrà salvato all'interno del file definito con il comando #SBATCH --output=%j-test.out , (%j fa riferimento all'ID del job e quindi dell'esecuzione), mentre nel caso siano stati riscontrati degli errori, potremo visualizzarli nel file che verrà creato grazie al comando #SBATCH --error=%j-test.err .

Ovviamente sarà possibile visualizzarli utilizzando il comando cat , quindi ad esempio, nel caso sia stato creato un job con ID 100, per poter visualizzare i due file possiamo eseguire i comandi

```
$ cat 100-test.out  
$ cat 100-test.err
```

Esecuzione parallela

Per effettuare l'esecuzione parallela è sufficiente avviare più comandi sbatch in successione.

Trasferimento modello Mistral su Leonardo

Per poter utilizzare Mistral su Leonardo, i passi sono simili a quelli effettuati per il modello Llama. In questo caso si è fatto riferimento, per scaricare il modello, al link

<https://github.com/mistralai/mistral-src?tab=readme-ov-file>

Per scaricare il file ZIP del modello si procede in modo analogo a ciò che è stato fatto per Llama, e successivamente per poter installare le dipendenze è necessario andare nella directory del modello ed utilizzare il comando

```
$ pip install -r requirements.txt
```

È necessario adesso iniziare il download del modello, in questo caso potremmo utilizzare i comandi


```
$ wget https://models.mistralcdn.com/mistral-7b-v0-1/mistral-7B-v0.1.tar
```

```
$ tar -xf mistral-7B-v0.1.tar
```

Noi quindi adesso abbiamo il modello che potremo trasferire su Leonardo in modo da poterlo utilizzare.

Come con Llama è però necessario applicare delle modifiche per poter definire i percorsi che deve utilizzare il modello per richiamare elementi necessari all'esecuzione.

A questo punto del processo dovremmo avere una situazione del genere



	Nome	Dimensione
	assets	8 oggetti
	deploy	2 oggetti
	mistral	7 oggetti
	mistral-7B-v0.1	5 oggetti
	__pycache__	1 oggetto
	tutorials	1 oggetto
	LICENSE	11,4 kB
	main.py	6,1 kB
	moe_one_file_ref.py	18,9 kB
	one_file_ref.py	12,0 kB
	README.md	8,2 kB
	requirements.txt	55 byte
	test_generate.py	2,8 kB

Adesso sarà necessario modificare alcune righe di codice per poter utilizzare il modello.

La prima modifica deve essere effettuata nel file main.py, il quale è uno script python che possiamo utilizzare per effettuare le richieste al modello.


Ciò che è necessario fare è modificare il percorso che fa riferimento al tokenizer.model, il quale si trova nella directory del modello scaricato, ovvero:

/ mistral-src-main / mistral-7B-v0.1	
Nome	Dimensione
 mistral-7B-v0.1	3 oggetti
 consolidated.00.pth	14,5 GB
 params.json	202 byte
 RELEASE	10,5 kB
 tokenizer.model	493,4 kB

Quindi le modifiche da apportare sono quelle visibili alle righe 142 e 115 dell'immagine seguente:

```
114 def interactive(model_path: str, max_tokens: int = 35, temperature: float = 0.7, instruct: bool = False):
115     tokenizer = Tokenizer(str(Path(model_path) / "/leonardo/" / "mistral-src-main/mistral-7B-v0.1/mistral-7B-
v0.1/tokenizer.model")) ##path for the tokenizer model
116     transformer = Transformer.from_folder(Path(model_path), max_batch_size=3)
117
118     while True:
119         prompt = input("Prompt: say hi and tol me something about Italy")
120         if instruct:
121             prompt = f"[INST] {prompt} [/INST]"
122         res, _logprobs = generate(
123             [prompt],
124             transformer,
125             tokenizer,
126             max_tokens=max_tokens,
127             temperature=temperature,
128         )
129         print(res[0])
130         print("=====")
131
132
133 def deno(
134     model_path: str, max_tokens: int = 35, temperature: float = 0.4, num_pipeline_ranks=1
135 ):
136     if num_pipeline_ranks > 1:
137         torch.distributed.init_process_group()
138         torch.cuda.set_device(torch.distributed.get_rank())
139         should_print = torch.distributed.get_rank() == 0
140     else:
141         should_print = True
142     tokenizer = Tokenizer(str(Path(model_path) / "/leonardo/" / "mistral-src-main/mistral-7B-v0.1/mistral-7B-
v0.1/tokenizer.model")) ##path for the tokenizer model
143     transformer = Transformer.from_folder(
144         Path(model_path), max_batch_size=3, num_pipeline_ranks=num_pipeline_ranks
145     )
146
147     res, _logprobs = generate(
148         [
149             "Say hi and tol me something about Italy",
150         ],
151         transformer,
152         tokenizer,
153         max_tokens=max_tokens,
154         temperature=temperature,
155     )
156     if should_print:
157         for x, l in zip(res, _logprobs):
158             print(x)
159             logging.debug('Logprobs: %s', l)
160             print("=====")
161
162 if name == "main":
```


Successivamente le altre modifiche devono essere applicate al file python chiamato `model.py`, il quale si trova nella cartella



The screenshot shows a file explorer window with the address bar set to 'Home / mistral-src-main / mistral'. The left sidebar contains navigation icons for 'Recenti', 'Preferiti', 'Home', 'Documenti', 'Immagini', 'Musica', 'Scaricati', 'Video', and 'Cestino'. The main area displays a list of files and folders:

Nome	Dimensione
__pycache__	6 oggetti
cache.py	8,2 kB
__init__.py	0 byte
model.py	13,8 kB
moe.py	1,1 kB
rope.py	882 byte
tokenizer.py	954 byte

Una volta aperto lo script è necessario apportare le modifiche che vediamo alle righe 355 e 369:



The screenshot shows a code editor window titled 'model.py' with the path '~/.mistral-src-main/mistral'. The code is Python and includes line numbers from 319 to 369. Two lines are highlighted in yellow:

```
355 with open("/leonardo/  
369 loaded = torch.load(str("/leonardo/
```

The full code snippet shown is:

```
319 skipped.add(k)  
320 elif k.startswith("norm") or k.startswith("output"):  
321     if self.pipeline_rank == self.num_pipeline_ranks - 1:  
322         state_to_load[k] = v  
323     else:  
324         logging.debug(  
325             "Skipping parameter %s at pipeline rank %d",  
326             k,  
327             self.pipeline_rank,  
328         )  
329     skipped.add(k)  
330 elif k.startswith("layers"):  
331     layer_id = k.split(".")[-1]  
332     if layer_id in self.layers:  
333         state_to_load[k] = v  
334     else:  
335         logging.debug(  
336             "Skipping parameter %s at pipeline rank %d",  
337             k,  
338             self.pipeline_rank,  
339         )  
340     skipped.add(k)  
341 else:  
342     raise ValueError(f"Unexpected key {k}")  
343 assert set(state_dict.keys()) == skipped.union(set(state_to_load.keys()))  
344 super().load_state_dict(state_to_load, *args, **kwargs)  
345  
346 @staticmethod  
347 def from_folder(  
348     folder: Path,  
349     max_batch_size: int = 1,  
350     num_pipeline_ranks: int = 1,  
351     device="cuda",  
352     dtype=torch.float16,  
353 ) -> "Transformer":  
354     #with open(folder / "params.json", "r") as f:  
355     with open("/leonardo/  
356         model_args = ModelArgs.from_dict(json.load(f))  
357     model_args.max_batch_size = max_batch_size  
358     if num_pipeline_ranks > 1:  
359         pipeline_rank = torch.distributed.get_rank()  
360     else:  
361         pipeline_rank = 0  
362     with torch.device("meta"):  
363         model = Transformer(  
364             model_args,  
365             pipeline_rank=pipeline_rank,  
366             num_pipeline_ranks=num_pipeline_ranks,  
367         )  
368     #loaded = torch.load(str(folder / "consolidated.00.pth"), mmap=True)  
369     loaded = torch.load(str("/leonardo/  
mmap=True)
```

Una volta fatto ciò potremo inviare il modello al cluster, sempre utilizzando il comando scp opportunamente modificato con il percorso del modello Mistral, per poi poterlo utilizzare.

Ovviamente le modifiche da apportare dipendono dal percorso dei file in base all'ambiente dove vogliamo utilizzarlo, quindi nel nostro caso, volendolo utilizzare su Leonardo, i percorsi fanno riferimento a quelli che poi avremo sul cluster.

Effettuato il trasferimento, dovremo creare un file .sh di SLURM anche per Mistral, il quale differisce da quello di Llama solo per il comando torchrun.

In questo caso il file SLURM è così definito:

```
#!/bin/bash
```

```
## Settaggi generali
```

```
#SBATCH --account=lscrC_SustLLMs_0
```

```
#SBATCH --partition=boost_usr_prod
```

```
#SBATCH --qos=normal
```

```
#SBATCH --time=00:05:00
```

```
#SBATCH --error=%j-test.err          ## File di errore
```

```
#SBATCH --output=%j-test.out         ## File output
```

```
#SBATCH --cpus-per-task=8            ## number of CPUs per process
```

```
#SBATCH --nodes=1                    ## Number of nodes
```

```
#SBATCH --ntasks-per-node=2          ## MPI processes per node
```

```
#SBATCH --mem-per-cpu=3000M
```

```
#SBATCH --gres=gpu:4
```

```
torchrun /leonardo/home/userexternal/rflore00/rom_env/mistral-src-main/main.py  
demo MODEL_PATH --max_tokens 500
```

In questo caso dopo /leonardo/home/userexternal/rflore00/rom_env/mistral-src-main/main.py viene inserito demo, il quale fa riferimento a quale modalità fare riferimento all'interno dello script main.py, nel dettaglio sarebbe possibile utilizzare la modalità demo o interactive, quest'ultima però non ci interessa.

Una volta trasferito anche il file SLURM al cluster, così come visto con Llama, sarà possibile poi eseguire il comando sbatch per avviare l'esecuzione.